

ĐẠI HỌC QUỐC GIA TP. HCM  
ĐH KHOA HỌC TỰ NHIÊN      VIỆN JOHN VON NEUMANN

NGUYỄN VĂN QUANG

TÓM TẮT LUẬN VĂN THẠC SĨ

# ƯỚC TÍNH DUNG LƯỢNG CỦA PIN LITHIUM-ION BẰNG CÁC PHƯƠNG PHÁP HƯỚNG DẪN LIỆU

Chuyên ngành:              Công nghệ thông tin và truyền thông  
Mã số chuyên ngành:    60.48.01

Tp. Hồ Chí Minh năm 2020



# Mục lục

<b>1</b>	<b>Giới thiệu</b>	<b>1</b>
1.1	Động lực nghiên cứu . . . . .	1
1.2	Định nghĩa bài toán . . . . .	1
1.3	Các tài liệu liên quan . . . . .	2
1.4	Một số khái niệm cơ bản . . . . .	3
1.4.1	SOH . . . . .	3
1.4.2	SOC . . . . .	3
1.5	Tổng quát về luận văn . . . . .	3
<b>2</b>	<b>Phương pháp đề xuất</b>	<b>4</b>
2.1	Phương pháp tiếp cận truyền thống để ước tính SOH . . . . .	4
2.1.1	Máy vectơ liên quan (RVM) . . . . .	4
2.1.2	Bộ lọc hạt (PF) . . . . .	5
2.2	Đề xuất phương pháp của Mạng nơron sâu . . . . .	5
2.2.1	Các lớp được kết nối đầy đủ . . . . .	6
2.2.2	Hàm mất mát . . . . .	6
2.3	Cấu trúc dữ liệu đầu vào . . . . .	8
<b>3</b>	<b>Thí nghiệm</b>	<b>8</b>
3.1	Quy trình thu thập dữ liệu pin . . . . .	9

3.2	Xử lý dữ liệu . . . . .	10
3.3	Chi tiết tiến hành thí nghiệm . . . . .	11
3.3.1	k-NN . . . . .	11
3.3.2	RVM . . . . .	12
3.3.3	Particle Filter . . . . .	12
3.3.4	Neural network . . . . .	13
<b>4</b>	<b>Kết quả thử nghiệm và so sánh</b>	<b>13</b>
4.1	Kết quả dự đoán SOH . . . . .	13
4.2	Thảo luận . . . . .	14
<b>5</b>	<b>Kết luận</b>	<b>15</b>
5.1	Kết luận . . . . .	15
5.2	Công việc trong tương lai . . . . .	16
	<b>Tài liệu tham khảo</b>	<b>16</b>

# Danh sách bảng

3.1	Thông tin chi tiết về pin lithium-ion. . . . .	9
3.2	Trạng thái quy trình SOH của pin lithium-ion . . . . .	9
3.3	Tóm tắt cấu hình của mô hình mạng Neural. . . . .	13
4.1	So sánh các chức năng dự đoán dung lượng hao hụt pin cho # 1 . . . . .	14
4.2	So sánh các chức năng dự đoán dung lượng hao hụt cho pin # 2 . . . . .	14



# Danh sách hình vẽ

2.1	Mạng kết nối đầy đủ của lớp $l_{(k-1)}$ và lớp $l_{(k)}$ với trọng số $w_{(k)}$ [1]	7
3.1	Đường cong dung lượng xả so với số chu kỳ sạc-xả đối với pin Li-ion.	10
3.2	Thiết lập thử nghiệm pin: (a) thiết lập thử nghiệm và (b) sơ đồ	11
3.3	Dữ liệu mẫu cho pin #1	12
3.4	Sự phân bố theo thời gian chu kỳ sạc điển hình của pin	12
4.1	Ước tính SOH với các thuật toán cơ bản và mạng nơ-ron cho pin #1	14
4.2	Ước tính SOH với các thuật toán cơ bản và mạng nơ-ron cho pin #2	15





# Chương 1

## Giới thiệu

### 1.1 Động lực nghiên cứu

Pin Lithium-ion là một loại pin sạc thường được sản xuất trên thị trường. Trong quá trình sạc, các ion dương ( $\text{Li}^+$ ) di chuyển từ cực âm thành cực dương và ngược lại trong quá trình phóng điện (thời gian sử dụng) để tạo ra dòng điện. Pin Lithium-ion chủ yếu được sử dụng cho các thiết bị di động, đặc biệt thiết bị đeo nhẹ. Tuy nhiên, nó đôi khi được sử dụng cho các vật thể chuyển động lớn như ô tô, máy bay không người lái, v.v. Trong hai thập kỷ gần đây, hệ thống điện sử dụng pin Lithium-ion đã nhận được sự quan tâm cao từ cộng đồng và đã được sử dụng trong rất nhiều thiết bị trên thị trường[2]. Do đó, cần bổ sung một số tính như an toàn, độ bền, số lần sạc,. Hơn nữa, yêu cầu bao gồm tối ưu hóa thiết kế để pin Lithium-ion có thời gian làm việc ổn định và bền bỉ. Trong một hệ thống quản lý pin, đôi khi được gọi là bộ pin, để đo đồng thời nhiều dữ liệu quan trọng từ các mô-đun pin Lithium-ion khác nhau. Trong số những dữ liệu đó, dung lượng pin hiện tại (SOC) và tình trạng sức khỏe (SOH) là đáng quan tâm nhất. Lý do là hầu như tất cả các ứng dụng thời gian thực / trực tuyến đều có liên quan trực tiếp hoặc gián tiếp vào SOC và SOH [3]. Do đó, hệ thống thời gian thực giúp để giám sát các mục dữ liệu này sẽ tạo ra sự hỗ trợ có ý nghĩa đối với các rủi ro về pin và tăng độ tin cậy của toàn bộ hệ thống.

### 1.2 Định nghĩa bài toán

Mục tiêu cuối cùng là có thể hiểu đầy đủ về hệ thống pin Lithium-ion và đề xuất một cách tiếp cận theo hướng dữ liệu bằng cách sử dụng Mạng thần kinh tạo thành một tùy chọn để ước lượng SOH dựa trên công suất của pin Lithium-ion

### 1.3 Các tài liệu liên quan

SOH cho biết khả năng lưu trữ năng lượng điện của pin và tỷ lệ phần trăm thường được sử dụng để cho biết tình trạng sức khỏe của pin. Here, soh được định nghĩa bởi [4]

$$\text{SOH} = \frac{\text{Capacity}_{\text{aged}}}{\text{Capacity}_{\text{rate}}} \times 100 \quad (1.1)$$

Trong đó  $\text{Capacity}_{\text{aged}}$  là dung lượng hiện tại của pin,  $\text{Capacity}_{\text{rate}}$  dung lượng định mức của pin.

Các nghiên cứu gần đây đề xuất nhiều phương pháp để ước lượng SOH. Các phương pháp này có thể được phân cụm thành ba nhóm:

1. Dựa trên mô hình thực nghiệm [5], [6].
2. Dựa trên mô hình điện hoá [7].
3. Dựa trên mô hình dữ liệu [8] và thuật toán học sâu [9]

Trong [5], Plett và các cộng sự đã sử dụng bộ lọc Kalman mở rộng cho hệ thống quản lý pin của gói pin trong xe hybrid-điện. Mô hình cho phép dự đoán SOC, nguồn điện giảm dần, giảm dần dung lượng và nguồn điện khả dụng tức thời và có thể thích ứng với việc thay đổi đặc tính của tế bào pin theo thời gian khi các tế bào trong bộ pin già đi. Họ xây dựng một mô hình toán học định lượng soc và trạng thái pin tên là Sigma-point Kalman filter. Dựa trên các kết quả nghiên cứu, họ ước tính gần đúng phân phối xác suất của SOC. Nhược điểm của phương pháp này là chúng rất phụ thuộc vào kết quả thực nghiệm và không đưa kiến thức vật lý vào trong mô hình.

Một phương pháp khác để ước tính là các mô hình điện hóa. Trong [7], Moura và cộng sự. đã phát triển một trình quan sát pde thích ứng để ước tính soc và SOH. Quan điểm của họ là thiết kế trạng thái đồng thời cho một pde tuyến tính với ánh xạ đầu ra phi tuyến. Chúng kết hợp thuật toán ước lượng với các biến vật lý, điện áp và dòng điện.

Các phương pháp khác là sử dụng mô hình ước tính xây dựng theo hướng dữ liệu. Những cách tiếp cận đó là phương pháp hiện đại vì chỉ phụ thuộc vào dữ liệu và không cần kiến thức sâu về pin. Với sự phát triển của internet vạn vật, công nghệ cảm biến đã thu thập một lượng lớn dữ liệu pin. Có rất nhiều tập dữ liệu về pin công khai: tập dữ liệu về sự lão hoá của pin như Oxford [10], Kho dữ liệu về tiên lượng của NASA [11], hiệu suất điện hóa của tập dữ liệu về tế bào lithium-ion định dạng 18650 thương mại [?]. Trong cách tiếp cận này, chúng tôi sử dụng dữ liệu để tìm hiểu mối quan hệ giữa các đặc điểm của SOH. Đặc điểm của tế bào là các phép đo dòng điện và điện áp. Phương pháp này cũng được nhóm lại thành 2 nhóm con [9]: hồi quy hạt nhân [8], [12] và học sâu [13], [14].

## 1.4 Một số khái niệm cơ bản

### 1.4.1 SOH

Khi thời gian sử dụng hoặc thời gian lưu trữ ngày càng tăng, dung lượng và công suất tối đa của các tế bào pin LIB sẽ từ từ giảm đến mức mà dung lượng hoặc công suất thấp không thể chấp nhận được nữa. SOH của tế bào pin đạt 0 %. Tuy nhiên, một tế bào LIB hoạt động trong các thông số kỹ thuật sẽ không bị chết đột ngột mà dần dần bị suy giảm hiệu suất. Sự xuống cấp này không chỉ xảy ra do sử dụng liên tục pin mà còn xảy ra trong quá trình bảo quản pin. Tuy nhiên, sự suy giảm hiệu suất trong quá trình nạp xả xảy ra nhanh hơn nhiều so với việc bảo quản trong cùng điều kiện.

### 1.4.2 SOC

Trạng thái sạc là biểu thị lượng năng lượng còn lại trong tế bào pin dưới dạng phần trăm dung lượng hiện tại. SOC càng cao, năng lượng được lưu trữ trong tế bào pin càng nhiều. Điều này có nghĩa là tế bào pin phản ứng mạnh hơn, điều này sẽ làm tăng tốc độ suy thoái của tế bào.

SOC nhanh chóng thay đổi, ảnh hưởng của SOC cao có thể bị hạn chế nếu các ô được xoay vòng ở mức SOC thấp. Đây là giả định rằng tế bào sẽ hoạt động trong phạm vi điện áp xác định do nhà sản xuất đưa ra. Trong trường hợp phóng điện quá mức hoặc phóng điện quá mức, sẽ được mô tả tương ứng, các cơ chế suy thoái khác sẽ được đưa vào và rút ngắn tuổi thọ của tế bào.

## 1.5 Tổng quát về luận văn

Trong chương 2, chúng tôi trình bày phương pháp học sâu theo chuỗi thời gian và kiến trúc của mô hình để ước tính SOH của pin. Chương 3 giới thiệu việc triển khai mô hình học sâu để kiểm chứng tính hiệu quả của phương pháp của chúng tôi. Trong chương 4, chúng tôi giải thích kết quả thực hiện và một số tương lai của

công việc có trong chương trước.

## Chương 2

# Phương pháp đề xuất

Chương này mô tả phương pháp được đề xuất để ước tính trực tuyến SOH. Trong phần 2.1, chúng tôi trình bày cách sử dụng phương pháp học máy truyền thống để ước tính SOH. Sau đó, phương pháp luận được áp dụng trong luận án này bao gồm một số bước như tiền xử lý dữ liệu, xác thực cho các mô hình hướng dữ liệu được đề xuất để chọn các giá trị tham số tốt nhất cho mô hình và lựa chọn mô hình hướng dữ liệu tốt nhất dựa trên kết quả thử nghiệm. Tiểu mục 2.2 hiển thị mô hình học sâu được sử dụng để đào tạo mô hình. Trong tiểu mục 2.3 mô tả chi tiết dữ liệu của bài toán.

## 2.1 Phương pháp tiếp cận truyền thống để ước tính SOH

### 2.1.1 Máy vectơ liên quan (RVM)

Cho dữ liệu đầu vào vectơ  $\{x_n\}_{n=1}^N$  và các tham số có thể điều chỉnh. SVM đưa ra dự đoán dựa trên hàm [15]:

$$y(\mathbf{x}; \mathbf{w}) = \sum_{i=1}^N w_i K(\mathbf{x}, \mathbf{x}_i) + w_0$$

trong đó  $K(\mathbf{x}, \mathbf{x}_i)$  là một hàm nhân. Máy vectơ mức độ liên quan (RVM) là phương pháp xử lý của Bayes đối với SVM [8] với phép đo xác suất. RVM tìm hiểu mối quan hệ ước tính giữa các tính năng liên quan (chẳng hạn như điện áp sạc, dòng sạc, điện trở, nhiệt độ, ..) và tình trạng sức khỏe của pin (SOC, SOH, ...). Để thực hiện phương pháp này, năm dữ liệu đặc trưng (trong [8]) chỉ ra hầu hết các tính năng quan trọng của đầu vào được trích xuất. Dữ liệu sau đó được đưa vào mô hình để làm gần đúng hàm phân phối Gauss. Sau đó, phân phối xác suất hoặc hàm mật độ xác suất (PDF) của đầu ra được tạo ra.

### 2.1.2 Bộ lọc hạt (PF)

Bộ lọc Hạt [16] được sử dụng rất sớm để dự đoán thời gian thực về pin và dữ liệu đo công suất LIB khác. Khung của Lọc hạt trong các nghiên cứu này tương tự nhau. Đầu tiên, chúng tạo ra một số hạt ngẫu nhiên. Các trọng số được cập nhật dựa trên sự đóng góp của nó với dữ liệu thực tế trong các bước đầu tiên. Sau một số lần lặp lại, các hạt có xác suất thấp từ dữ liệu đo được thực tế sẽ bị loại bỏ và các hạt còn lại sẽ tiếp tục được phát triển. Cuối cùng, đầu ra của mô hình PF là các hạt có trọng số cũng như trung bình và hiệp phương sai. Bộ lọc Hạt rất mạnh trong phép nội suy mối quan hệ phi tuyến tính và phi Gauss. Tuy nhiên, phương pháp lấy mẫu lại trọng lượng hạt cần cách tiếp cận chủ quan có thể dẫn đến việc loại bỏ sai dữ liệu tính năng và do đó hạn chế độ chính xác đầu ra của nó. k-Nearest-Neighbor (kNN) kNN là một cách đơn giản, trực quan và hiệu quả để ước tính giá trị của một hàm chưa biết tại một điểm đã cho bằng cách sử dụng các giá trị của nó trong các điểm (đào tạo) khác [?]. Cho  $S = x_1, \dots, x_m$  là tập hợp các điểm rèn luyện. Công cụ ước lượng kNN được định nghĩa là giá trị hàm trung bình của các nước láng giềng gần nhất.

$$\hat{f}(x) = \frac{1}{k} \sum_{x \in N(x)} f(x') \quad (2.1)$$

trong đó  $N(x) \subseteq S$  là tập hợp  $k$  điểm gần nhất với  $x$  trong  $S$  và  $k$  là một tham số.

## 2.2 Đề xuất phương pháp của Mạng nơ-ron sâu

Mạng nơ-ron là một trong những thuật toán nhận dạng các mẫu và đã được sử dụng trong nhiều vấn đề [17]. Trong phần này, chúng tôi sẽ thảo luận và chỉ ra một số thuật ngữ về mạng nơ-ron được sử dụng trong luận văn này một cách ngắn gọn.

Mạng nơ-ron là những đồ thị có trọng số, có các lớp theo thứ tự. Các mạng nơ-ron có một lớp đầu vào, (các) lớp ẩn và lớp đầu ra, theo tuần tự. Các lớp là một nhóm các nút. Các nút thuộc một lớp được kết nối với các nút ở lớp sau và / hoặc lớp trước. Các kết nối này là các cạnh có trọng số và chúng được gọi là trọng số [1]. Cho một đầu vào, các nút mạng nơ-ron có đầu ra là các số thực. Đầu ra của một nút được tính bằng cách áp dụng một hàm ( $\psi$ ) cho đầu ra của các nút thuộc các lớp trước đó. Trước đó, đầu ra của lớp đầu vào ( $o^{(0)}$ ) bằng với đầu vào (xem Phương trình. 2.2). Bằng cách tính toán các kết quả đầu ra của lớp liên tiếp, chúng tôi tính toán đầu ra của lớp đầu ra. Quá trình này được gọi là suy luận [18]. Đầu ra của nút  $i$  trong lớp  $k$  xác định bằng:

$$o^{(k)} = \begin{cases} \psi_k(o^{(k-1)}), & \text{if } k \geq 1, \\ x_n, & k = 0 \end{cases} \quad (2.2)$$

Trong đó,

- $L$ : Số lượng lớp
- $l^{(k)}$ : Lớp thứ  $k$
- $m^{(k)}$ : Số lượng nút trong  $l^{(k)}$
- $l_i^{(k)}$ : Nút  $i$  trong  $l^{(k)}$
- $o^{(k)}$ : Vector đầu ra đại diện cho  $l^{(k)}$
- $\psi_k$ : : hàm xác định  $o^{\psi_k}$  cho trước  $o^{\psi_{k-1}}$
- $x_n$ :  $n$ th dữ liệu đầu vào

### 2.2.1 Các lớp được kết nối đầy đủ

Để hai lớp liên tục tiếp theo được kết nối đầy đủ, tất cả các nút ở lớp trước phải được kết nối với tất cả các nút trong lớp sau.

Giả sử hai lớp liên tục,  $l_{(k-1)}$  và  $l_{(k)}$  với số nút lần lượt là  $m_{(k-1)}$  và  $m_{(k)}$ . Để các lớp này được kết nối đầy đủ, ma trận kết nối chúng sẽ là  $w^{(k)} \in m^{(k-1) \times m^{(k)}}$  (hình 2.1).


### 2.2.2 Hàm mất mát

Để thể hiện chất lượng của mạng nơ-ron, chúng ta sẽ sử dụng hàm tổn thất (hoặc chi phí). Có hai thuộc tính của hàm mất mát. Thứ nhất, tổn thất thường lớn hơn hoặc bằng 0, không bao giờ âm. Thứ hai, với hai mạng nơ-ron, mạng nào có tổn thất nhỏ hơn thì tốt hơn mạng khác. Ma trận đánh giá trong luận văn bao gồm sai số trung bình căn bậc hai (RMSE), sai số lớn nhất (ME), sai số tương đối lớn nhất (MRE) và sai số trung bình (AE) .

#### Sai số trung bình căn bậc hai

Cho một dự đoán  $\hat{y}_n \in \mathbb{R}^n$  và giá trị thực sự  $y_n \in \mathbb{R}^n$ , rmse is Eq. 2.3

$$\mathcal{L} = \text{RMSE}(\hat{y}, y) = \sqrt{\frac{\sum_{n=1}^N (\hat{y}_i - y_i)^2}{N}} \quad (2.3)$$



Hình 2.1: Mạng kết nối đầy đủ của lớp  $l_{(k-1)}$  và lớp  $l_{(k)}$  với trọng số  $w_{(k)}$  [1]

**Sai số lớn nhất (ME)**

$$\mathcal{L} = \text{ME}(\hat{y}, y) = \max\{|\hat{y}_i - y_i|\}_{i=1}^N \quad (2.4)$$

**Sai số tương đối lớn nhất (MRE)**

$$\mathcal{L} = \text{MRE}(\hat{y}, y) = \max\left\{\frac{|\hat{y}_i - y_i|}{y_i}\right\}_{i=1}^N \quad (2.5)$$

**Sai số trung bình(AE)**

$$\mathcal{L} = \text{AE}(\hat{y}, y) = \frac{\sum_{i=1}^N |\hat{y}_i - y_i|}{N} \quad (2.6)$$

## 2.3 Cấu trúc dữ liệu đầu vào

Mặc dù pin có nhiều khía cạnh ảnh hưởng đến sự lão hóa, bao gồm nhiệt độ và thành phần hóa học của chúng. Không thể tính đến tất cả các yếu tố phản ánh vào mô hình ước lượng nhưng chúng tôi cho rằng sử dụng tập hợp con của các yếu tố đó để xây dựng một khuôn khổ xử lý chúng. Trong luận án này, chúng tôi đề cập đến ba tính năng (điện áp, dòng điện và nhiệt độ) từ cảm biến pin:

$$\mathbf{X} = \begin{pmatrix} I_1 & V_1 & T_1 \\ I_2 & V_2 & T_2 \\ \vdots & \vdots & \vdots \\ I_m & V_m & T_m \end{pmatrix}$$

Trong đó  $I_t, V_t, T_t$  lần lượt là dòng điện, điện áp và nhiệt độ, tại thời điểm  $t$  và  $m$  là số bộ phận tùy ý trong chu kỳ sạc. Trong khoá luận này, phân phối chung  $X \in \mathbf{R}^{m \times 3}$  cùng đại diện cho dữ liệu tại thời điểm  $t$  như một điểm dữ liệu

Đối với mỗi điểm dữ liệu, có một đầu ra công suất phóng điện tương ứng  $y$ , là một số vô hướng và được tính toán bằng phương pháp đếm coulomb, tích hợp dòng phóng điện theo thời gian cho toàn bộ chu kỳ phóng điện [9]. Mô hình cố gắng tìm một ánh xạ hàm phi tuyến tính từ  $\mathbf{R}^{m \times 3}$  đến  $\mathbf{R}^1$ .

# Chương 3

## Thí nghiệm

### Tóm tắt

Hiệu quả của phương pháp học sâu được đề xuất đã được xác minh dựa trên dữ liệu thực nghiệm từ thử nghiệm chu kỳ (tức là, chu kỳ sạc đầy / xả lặp lại) trên các tế bào hình lăng trụ Li-ion. Phần này 3.1 giới thiệu quy trình thu thập dữ liệu pin. Sau đó, trong phần 3.2, chúng ta thảo luận về cách làm sạch dữ liệu, chuyển đổi dữ



liệu sang định dạng mà chúng ta có thể cung cấp cho mạng thần kinh. Cuối cùng, trong phần 3.3, chúng tôi cho thấy việc triển khai đào tạo, xác thực và kiểm tra mạng nơ-ron trong xác minh thử nghiệm này.

### 3.1 Quy trình thu thập dữ liệu pin

Bảng 3.1: Thông tin chi tiết về pin lithium-ion.


Parameters	Value
Chemical component	$Li(NiCoMn)O_2$
Capacity	3000 mAh
Nominal voltage	3.7V
Working voltage	2.7 - 4.2
Discharge current at 1C	3A
Working temperature	$0 - 55^{\circ}C$

Bảng 3.2: Trạng thái quy trình SOH của pin lithium-ion

Step	Battery operation	Control value	Extra Control Value
1	Charging	Constant Current: 1.3A Constant Voltage: 4.2V	Voltage Limit = 4.2V Charging Current $\leq 0.05A$
2	Rest	Time: 30 min	
3	Discharging	Constant Current: -1.3 A	Discharging Voltage $\leq 2.75\text{ V}$
4	Rest	Time: 30 min	

Trước khi đặt dữ liệu pin làm dữ liệu thử nghiệm, chúng tôi xử lý trước dữ liệu bằng cách làm sạch dữ liệu, loại bỏ các điểm ngoại lệ. Cuối cùng, chúng tôi thu được một bộ dữ liệu pin với các đặc tính suy giảm trên mỗi chu kỳ như được trình bày trong Bảng. 3.1. Bảng 3.2 tóm tắt quy trình kiểm tra SOH. Điện áp làm việc của mỗi pin được đặt từ 2,7V đến 4,2V. Kiểm tra chu kỳ được thực hiện bởi hệ thống kiểm tra pin với tốc độ sạc và xả ở mức 0,5 C. Mỗi chu kỳ bao gồm bốn bước: sạc, nghỉ, xả và nghỉ. Bước nghỉ ngơi được thực hiện để giảm lỗi do điều kiện hoạt động. Quá trình sạc pin được thực hiện ở dòng điện không đổi 1,3 A cho đến khi điện áp của pin đạt đến giới hạn 4,2V và sau đó ở điện áp không đổi là 4,2 V cho đến khi dòng điện giảm xuống 0,05A, sau đó nghỉ 30 phút. Hơn nữa, pin được phóng ở dòng điện không đổi -1,3 A cho đến khi điện áp phóng đạt 2,75 V, sau đó nghỉ 30 phút. Ngoài ra, nhiệt độ môi trường thử nghiệm được đặt ở 25 độ C.

Sự thay đổi về khả năng xả của pin qua các chu kỳ sạc cho 2 pin thử nghiệm được mô tả trong Hình. 3.1 được tính bằng cách tích phân dòng xả trong khoảng thời gian của chu kỳ xả. Có thể quan sát thấy từ Hình. 3.1 cho rằng mỗi pin có biểu hiện giảm dung lượng ít đồng nhất hơn so với chỉ số chu kỳ. Mục tiêu của chúng tôi là điều tra xem liệu mô hình mạng nơ-ron có thể nắm bắt được các ước tính dung lượng cho pin theo chu kỳ với các giao thức và cấu hình chu kỳ khác nhau hay không. Để sử dụng pin an toàn và đáng tin cậy, có thể sử dụng ngưỡng dung lượng pin để xác định SOC của pin. Thông thường, mức ngưỡng được quy định là 70-80 phần trăm (tùy thuộc vào hoạt động của pin) của dung lượng pin định mức. Hình.3.2 cho thấy việc thiết lập



Hình 3.1: Đường cong dung lượng xả so với số chu kỳ sạc-xả đối với pin Li-ion.

hệ thống thử nghiệm của chúng tôi. Hình. 3.2 a là sơ đồ của phần cứng thử nghiệm với các côn cụ đo lường và bộ pin và Hình. 3.2 b là sơ đồ đầu vào của các Kênh thử nghiệm cung cấp các điều kiện khác nhau cho thử nghiệm của chúng tôi trong khi Bảng điều khiển giám sát hiển thị dữ liệu nhật ký của quá trình thay đổi hoặc xả. Arbin lưu trữ thông tin đo lường trong bộ lưu trữ cục bộ của nó và có thể được trích xuất sau này.

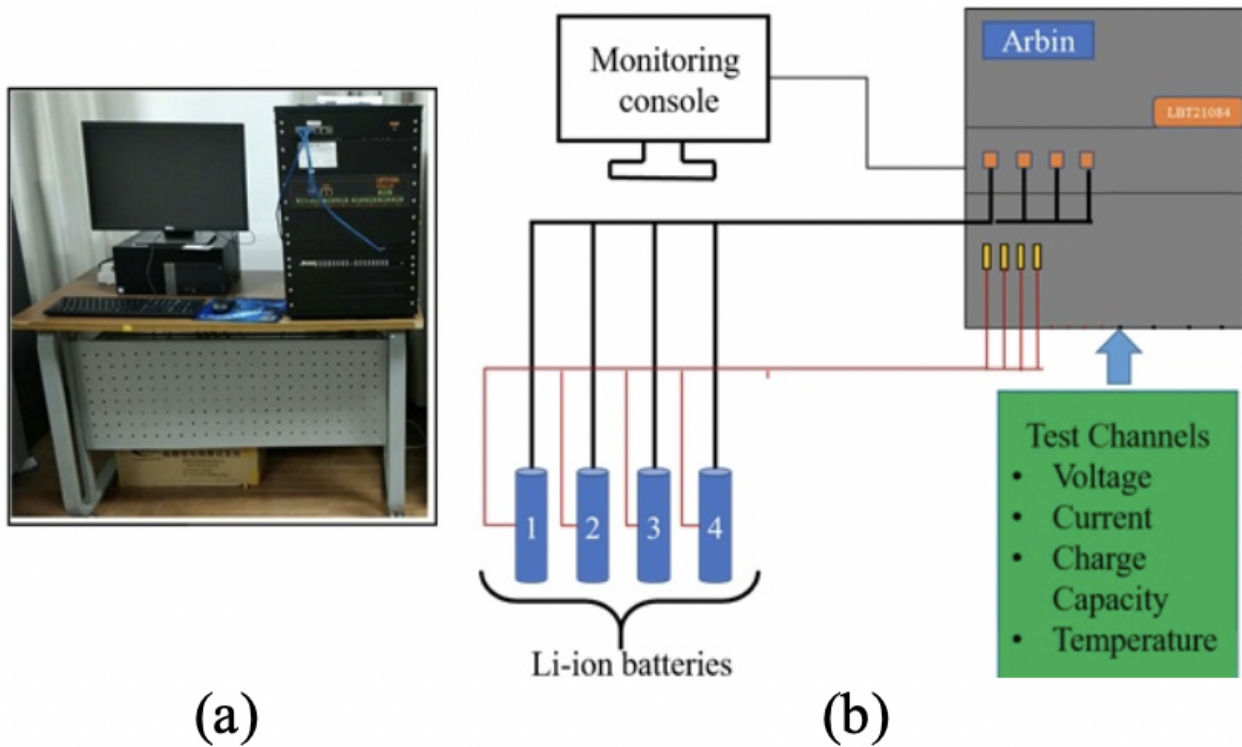
SOH của pin được xác định bằng cách theo dõi dung lượng pin ở mức có thể sạc lại được ( $C_{releasable}$ ) và ở mức có thể sạc được tối đa ( $C_{max}$ ) đối với dung lượng pin mới. ( $C_{rated}$ ) như được định nghĩa trong công thức:

$$SOH = \frac{C_{max}}{C_{rated}} \times 100$$

## 3.2 Xử lý dữ liệu

Dữ liệu đầu vào của chúng tôi là tập hợp pin từ ngày 14 tháng 9 năm 2018 đến ngày 16 tháng 1 năm 2019. Dữ liệu bao gồm 2.777.529 điểm dữ liệu cho cả 2 pin. Dữ liệu được thu thập qua 125 chu kỳ cho mỗi pin. Phần đầu và phần đuôi của chu kỳ đầu tiên của pin # 1 được hiển thị trong Hình. 3.3.

Từ mỗi chỉ số chu kỳ, chúng tôi đã tính được  $SOH = \frac{\text{dung lượng xả tối đa ở bước 3}}{\text{tỷ lệ dung lượng pin} = 3000 \text{ mAh}}$ . Như chúng tôi thảo luận trong 2.3, đối với mỗi chu kỳ tích điện một phần, chúng ta chọn  $m = 25$  cho mỗi phân bố điện áp, dòng điện và dung lượng tích điện. Để hiển thị tốt hơn các đầu vào, phân bố điện áp, dòng điện và dung lượng sạc được hiển thị trong Hình. 3.4. Mỗi phân phối đó được tùy biến thành các phân đoạn  $m = 25$ , sau đó phân bố chúng



Hình 3.2: Thiết lập thử nghiệm pin: (a) thiết lập thử nghiệm và (b) sơ đồ

thành một vectơ trong  $\mathbf{R}^{75}$ .

### 3.3 Chi tiết tiến hành thí nghiệm

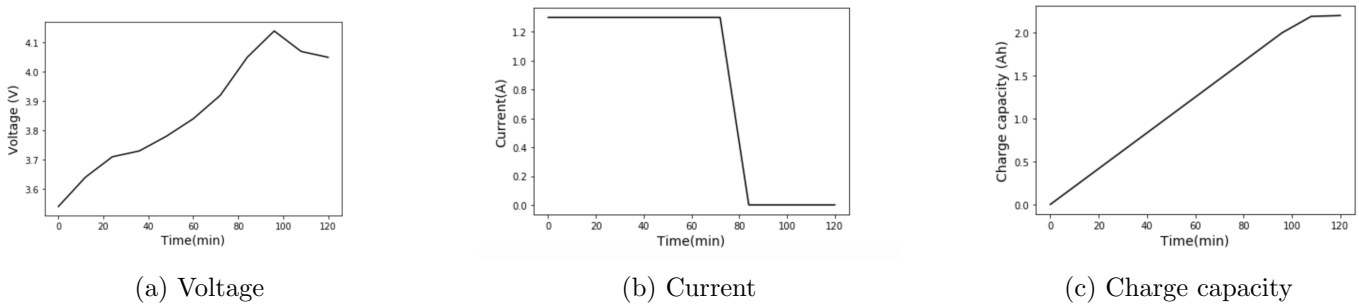
Mục tiêu của mô hình là giảm sai số tổng quát dự kiến được đưa ra bởi phương trình. 2.3. Để đạt được mục tiêu này, chúng tôi sẽ sử dụng tập dữ liệu để đào tạo và đánh giá. Bằng cách triển khai các phương pháp hướng dữ liệu (kNN, RVM, Bộ lọc hạt) và mô hình mạng nơron sâu, chúng ta sẽ đi đến một so sánh sẽ được mô tả trong Chương 4. Trong phần sau, chúng tôi mô tả cách các phương pháp trên hoạt động trên dữ liệu của chúng tôi.

#### 3.3.1 k-NN

Dữ liệu tại mỗi điểm được ước tính bởi một tập hợp  $N$  láng giềng gần nhất;  $N$  được sử dụng như một siêu tham số. Thuật toán k-NN sử dụng khái niệm tương tự để tính gần đúng giá trị của một điểm dữ liệu mới. Trong ứng dụng của chúng tôi, giá trị dự đoán mới được chỉ định một giá trị dựa trên mức độ gần giống với các điểm trong tập huấn luyện. Chúng tôi ước tính điểm  $N$  gần nhất với giá trị dự đoán và lưu trữ kết quả trung bình từ chúng. Trong xác nhận và so sánh, sai số được tính bằng chênh lệch so với dự đoán và giá trị thực tế.

	Date_Time	Test_Time(s)	Step_Index	Cycle_Index	Voltage(V)	Current(A)	Charge_Capacity(Ah)	Discharge_Capacity(Ah)
0	2018-09-14 16:39:49.863	60.010500	1	1	3.530674	1.299788	0.021548	1.761754e-09
1	2018-09-14 16:40:49.864	120.011800	1	1	3.558775	1.299831	0.043207	1.761754e-09
2	2018-09-14 16:41:49.853	180.000900	1	1	3.570162	1.299841	0.064868	1.761754e-09
3	2018-09-14 16:42:49.861	240.008900	1	1	3.576921	1.299820	0.086534	1.761754e-09
4	2018-09-14 16:43:49.860	300.007800	1	1	3.583076	1.299814	0.108199	1.761754e-09
...	...	...	...	...	...	...	...	...
234	2018-09-14 20:33:09.818	14059.965792	3	1	3.058974	-1.299524	2.216611	2.209313e+00
235	2018-09-14 20:34:09.820	14119.967692	3	1	2.996843	-1.299570	2.216611	2.230957e+00
236	2018-09-14 20:35:09.817	14179.964792	3	1	2.920110	-1.299566	2.216611	2.252634e+00
237	2018-09-14 20:36:09.816	14239.963192	3	1	2.821015	-1.299526	2.216611	2.274287e+00
238	2018-09-14 20:36:42.607	14272.754892	3	1	2.749995	-1.299587	2.216611	2.286119e+00

Hình 3.3: Dữ liệu mẫu cho pin #1



Hình 3.4: Sự phân bố theo thời gian chu kỳ sạc điện hình của pin

### 3.3.2 RVM

Bằng cách sử dụng dữ liệu đầu vào, RVM được đào tạo thông qua tất cả các chu kỳ được thu thập. Rõ ràng, các tính năng quan trọng của tế bào pin phản ánh dự đoán về các tính năng thích hợp làm đầu ra. Do đó, dữ liệu CNN sẽ được sử dụng để so sánh với dữ liệu của RVM sẽ được đào tạo trên tập dữ liệu đầy đủ nhưng dự đoán trên các giá trị đầu ra hạn chế.

### 3.3.3 Particle Filter

Bộ lọc hạt (PF) được sử dụng để dự đoán dung lượng của mọi điểm trong các chu kỳ, tương tự như cách tiếp cận mạng nơ-ron sau này. Chúng tôi tạo một danh sách các hạt  $P$  ( $P$  là một tham số), dự đoán và cập nhật trọng lượng dựa trên khoảng cách đến điểm thực tế. Lấy lại mẫu được sử dụng để loại bỏ các hạt có khả năng xảy ra thấp nhất. Trong dự đoán cho trạng thái pin điểm mới, đầu ra của PF (giá trị trung bình và hiệp phương sai cùng với các phần tử của điểm trước đó) cung cấp ước tính. Và các lỗi đối với dữ liệu thực tế trong xác nhận được sử dụng để so sánh với các phương pháp khác.

### 3.3.4 Neural network

Mô hình mạng nơron đã được đào tạo với 100 epochs và một nhóm nhỏ gồm 128 mẫu. Tóm tắt cấu hình mô hình được hiển thị trong Bảng 3.3. Một phần của tập dữ liệu của chúng tôi được sử dụng để đào tạo (80%) và phần còn lại được sử dụng để kiểm chứng (20 %). Trong chương tiếp theo, chúng tôi sẽ mô tả chi tiết kết quả thử nghiệm của chúng tôi.

Bảng 3.3: Tóm tắt cấu hình của mô hình mạng Neural.

Layer	Kernel size	Number of kernels
Input	25 x 3 x 1	-
Conv. 1	1 x 2 x 1	16
Max pooling	3 x 1 x 1	-
Conv. 2	3 x 1 x 1	32
Conv. 3	1 x 2 x 1	40
Conv. 4	1 x 2 x 1	40
Conv. 5	1 x 2 x 1	40
FC. 1	40 x 1	-
FC. 2	40 x 1	-
FC. 3	1 x 1	-

## Chương 4

# Kết quả thử nghiệm và so sánh

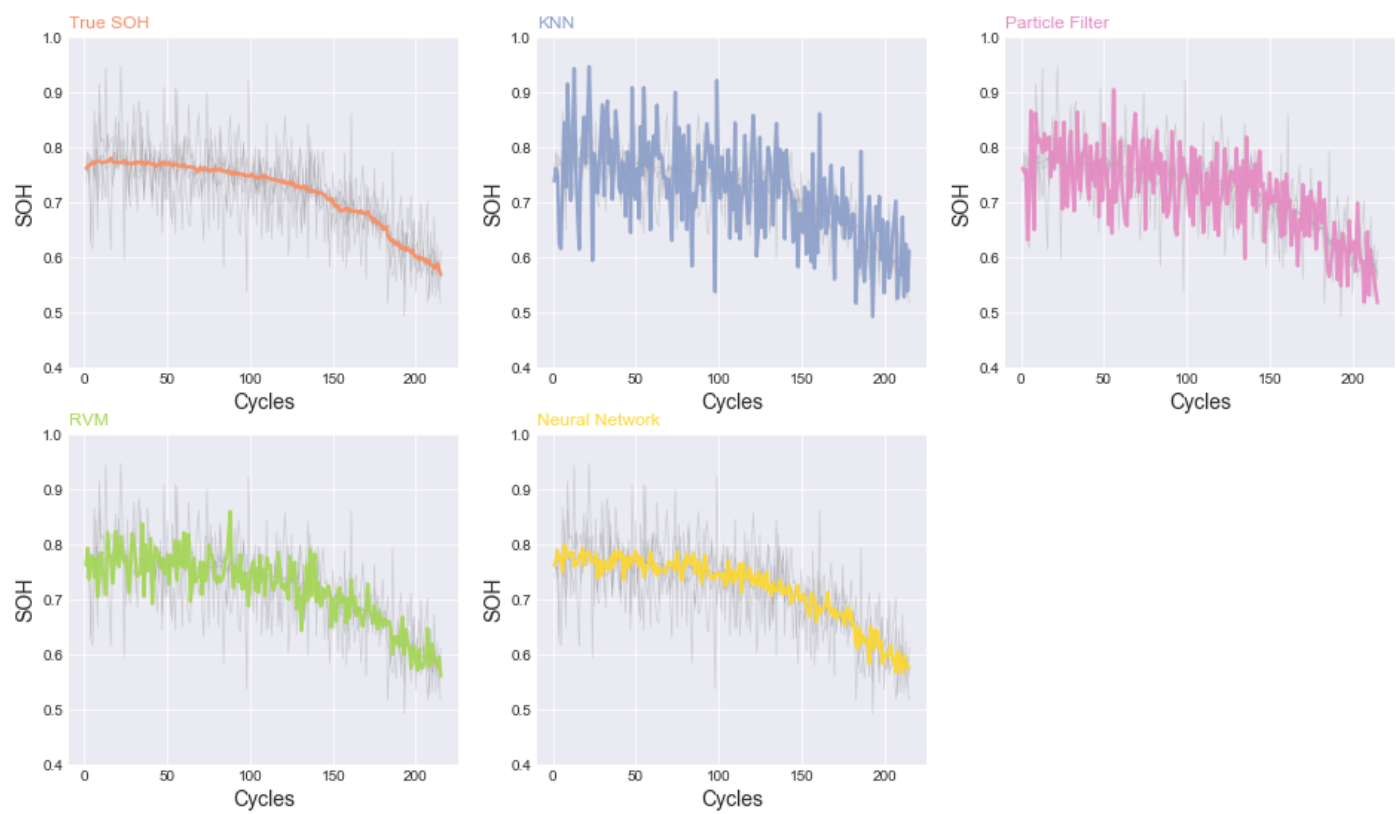
### Tóm tắt

Chương này trình bày chi tiết tất cả các kết quả của luận án của tôi, nó cũng chứa đựng đầy đủ các thảo luận, diễn giải và đánh giá kết quả.

### 4.1 Kết quả dự đoán SOH

Kết quả ước tính SOH trong toàn bộ vòng đời của pin # 1 và # 2 được hiển thị trong Hình 4.1 và 4.2. Để đánh giá thêm hiệu quả của phương pháp đề xuất, các thuật toán k-NN, Bộ lọc hạt, RVM và Mạng thần kinh

được so sánh trong các thí nghiệm. Bảng 4.1 và 4.2 hiển thị định lượng các kết quả so sánh hiệu suất.



Hình 4.1: Ước tính SOH với các thuật toán cơ bản và mạng nơ-ron cho pin #1

Bảng 4.1: So sánh các chức năng dự đoán dung lượng hao hụt pin cho # 1

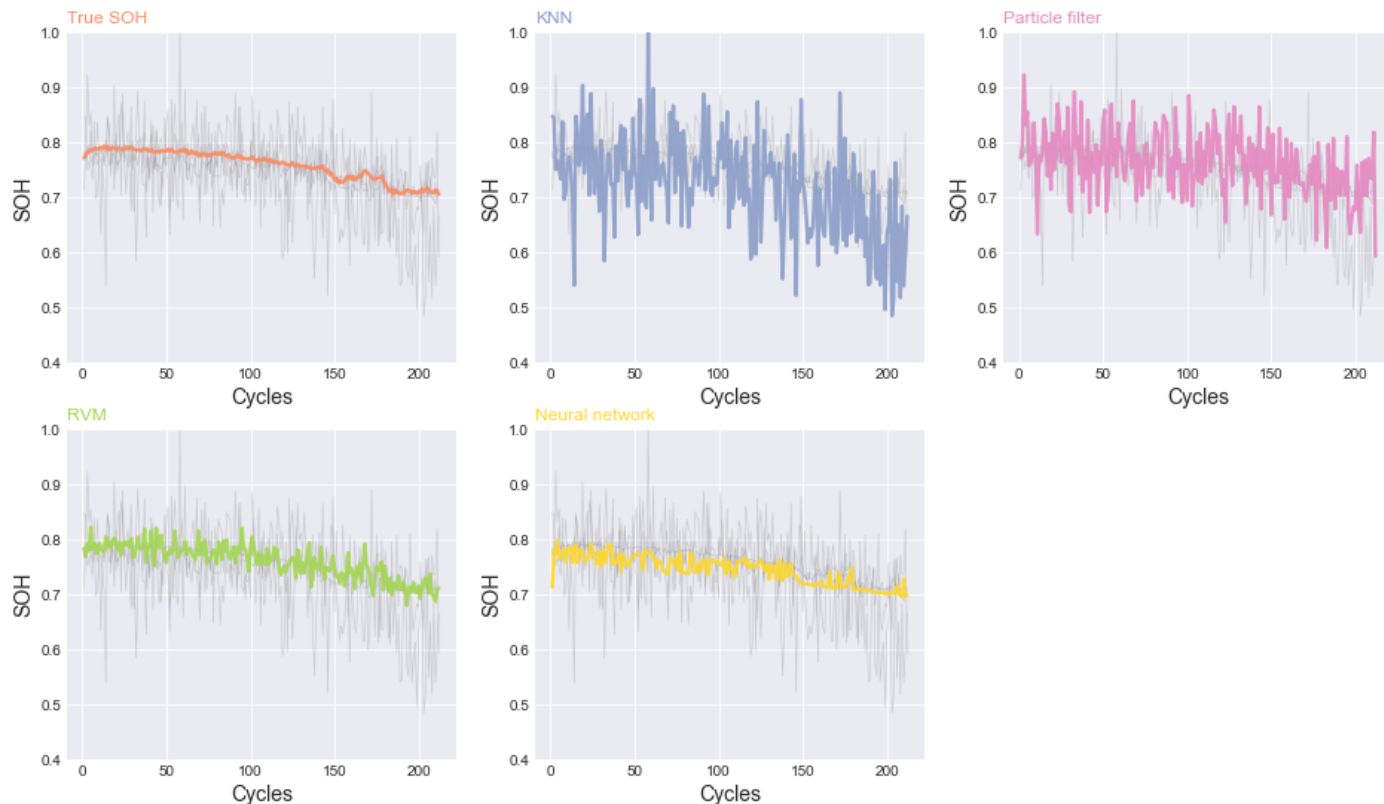
Cost function	KNN	Particle filter	RVM	Neural network
RMSE	0.072	0.053	0.029	0.013
ME	0.209	0.137	0.106	0.034
MRE	0.280	0.179	0.140	0.053
AE	0.00130	0.00083	0.00065	0.00025

Bảng 4.2: So sánh các chức năng dự đoán dung lượng hao hụt cho pin # 2

Cost function	KNN	Particle filter	RVM	Neural network
RMSE	0.088	0.054	0.019	0.018
ME	0.248	0.157	0.059	0.050
MRE	0.315	0.198	0.076	0.064
AE	0.00149	0.00094	0.00036	0.00030

## 4.2 Thảo luận

Từ bảng 4.1 và bảng 4.2, có thể thấy rằng các phương pháp mạng nơron có hiệu suất tốt trong ước tính SOH của pin và sai số tương đối tối đa của ước lượng SOH là từ 5-6 %. Điều này cho thấy phương pháp này phù hợp với hệ thống phi tuyến tính như pin lithium-ion. Hơn nữa, phương pháp được đề xuất có khả năng thích



Hình 4.2: Ước tính SOH với các thuật toán cơ bản và mạng nơ-ron cho pin #2

ứng tốt trên các loại pin lithium-ion khác nhau.

## Chương 5

# Kết luận

Chương này cung cấp một bản tóm tắt về các công việc được thực hiện trong luận án này. Một kết luận tổng thể sau đó được rút ra và phạm vi cho công việc tương lai mở rộng trên luận án này cũng được đặt ra.

### 5.1 Kết luận

Mục tiêu chính của luận án này là phát triển và tối ưu hóa hệ thống giám sát trực tuyến cho pin lithium-ion có thể thích ứng với những thay đổi do các điều kiện hoạt động khác nhau. Nhiều phương pháp khác nhau đã được đề xuất từ các phương pháp tiếp cận hóa học, vật lý, thống kê và thực nghiệm. Tuy nhiên, rất khó để xác định tuổi thọ của chu kỳ vì pin đang hoạt động hiếm khi trải qua quá trình sạc / xả đầy. Luận án

này đã phát triển các tham số phù hợp và một mô hình mới để ước lượng SOH. Việc thăm dò kỹ lưỡng dữ liệu thử nghiệm cho thấy rằng một biến mới, đơn vị thời gian điện áp, dòng điện và nhiệt độ trong quá trình sạc, thích hợp cho việc lập mô hình SOH. Phương trình SOH mới được suy ra là tuyến tính, nhưng có hệ số sửa đổi là một hàm của SOC. Các mô hình SOH được đề xuất cho thấy độ chính xác tuyệt vời khi được sử dụng để ước tính cùng một lô tập dữ liệu pin thử nghiệm. Độ bền của mô hình cũng đã được kiểm tra và kết quả cho thấy rằng việc sử dụng bất kỳ một loại pin nào để xây dựng mô hình đều mang lại độ chính xác tương tự.

Luận án này nhằm phát triển một mô hình ước lượng để tăng ước lượng SOH cho các ứng dụng quan trọng về an toàn. Và cũng để làm cho pin lithium-ion trở thành sự lựa chọn an toàn và hấp dẫn hơn cho một loạt các ứng dụng sử dụng pin. Nói chung, phương pháp được đề xuất trong luận án này sẽ cho phép sử dụng pin lithium-ion tốt hơn bằng cách liên tục theo dõi các SOH của chúng mà không cần phải thực hiện các bài kiểm tra đặc tính tốn kém và tốn thời gian vốn không lý tưởng về mặt thực tế.

## 5.2 Công việc trong tương lai

Phần kết luận đã cho thấy công việc trong luận án và những lợi ích mang lại so với hiện đại, có những lĩnh vực mà luận án này có thể mở rộng. Trong tương lai, phương pháp được đề xuất có thể được mở rộng bằng cách tính đến một phương pháp trực tuyến cập nhật các tham số của các phương trình dựa trên vật lý ảnh hưởng đến sự xuống cấp thực tế trong hoạt động thực tế thời gian thực.

# Tài liệu tham khảo

- [1] Andrew Lavin and Scott Gray. Fast algorithms for convolutional neural networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4013–4021, 2016.
- [2] Xinyu Liang, Nengsheng Bao, Jian Zhang, Akhil Garg, and Shuangxi Wang. Evaluation of battery modules state for electric vehicle using artificial neural network and experimental validation. *Energy Science & Engineering*, 6(5):397–407, 2018.
- [3] Wladislaw Waag, Christian Fleischer, and Dirk Uwe Sauer. Critical review of the methods for monitoring of lithium-ion batteries in electric and hybrid vehicles. *Journal of Power Sources*, 258:321–339, 2014.



- [4] P Ramadass, Bala Haran, Ralph White, and Branko N Popov. Mathematical modeling of the capacity fade of li-ion cells. *Journal of power sources*, 123(2):230–240, 2003.
- [5] Gregory L Plett. Extended kalman filtering for battery management systems of lipb-based hev battery packs: Part 3. state and parameter estimation. *Journal of Power sources*, 134(2):277–292, 2004.
- [6] Benjamín E Olivares, Matias A Cerda Munoz, Marcos E Orchard, and Jorge F Silva. Particle-filtering-based prognosis framework for energy storage devices with a statistical characterization of state-of-health regeneration phenomena. *IEEE Transactions on Instrumentation and Measurement*, 62(2):364–376, 2012.
- [7] Scott J Moura, Nalin A Chaturvedi, and Miroslav Krstić. Adaptive partial differential equation observer for battery state-of-charge/state-of-health estimation via an electrochemical model. *Journal of Dynamic Systems, Measurement, and Control*, 136(1), 2014.
- [8] Chao Hu, Gaurav Jain, Craig Schmidt, Carrie Strief, and Melani Sullivan. Online estimation of lithium-ion battery capacity using sparse bayesian learning. *Journal of Power Sources*, 289:105–113, 2015.
- [9] Sheng Shen, Mohammadkazem Sadoughi, Xiangyi Chen, Mingyi Hong, and Chao Hu. A deep learning method for online capacity estimation of lithium-ion batteries. *Journal of Energy Storage*, 25:100817, 2019.
- [10] Christoph Birkel. Oxford battery degradation dataset 1. 2017.
- [11] A Agogino and K Goebel. Mill data set. best lab, uc berkeley. nasa ames prognostics data repository, 2007.
- [12] Chao Hu, Gaurav Jain, Puqiang Zhang, Craig Schmidt, Parthasarathy Gomadam, and Tom Gorka. Data-driven method based on particle swarm optimization and k-nearest neighbor regression for estimating capacity of lithium-ion battery. *Applied Energy*, 129:49–55, 2014.
- [13] Gae-won You, Sangdo Park, and Dukjin Oh. Real-time state-of-health estimation for electric vehicle batteries: A data-driven approach. *Applied Energy*, 176:92–103, 2016.
- [14] LiuWang Kang, Xuan Zhao, and Jian Ma. A new neural network model for the state-of-charge estimation in the battery degradation process. *Applied Energy*, 121:20–27, 2014.
- [15] Michael E Tipping. Sparse bayesian learning and the relevance vector machine. *Journal of machine learning research*, 1(Jun):211–244, 2001.
- [16] Datong Liu, Xuehao Yin, Yuchen Song, Wang Liu, and Yu Peng. An on-line state of health estimation of lithium-ion battery using unscented particle filter. *Ieee Access*, 6:40990–41001, 2018.
- [17] Martin T Hagan, Howard B Demuth, and Mark Beale. *Neural network design*. PWS Publishing Co., 1997.

- [18] Michaël Defferrard, Xavier Bresson, and Pierre Vandergheynst. Convolutional neural networks on graphs with fast localized spectral filtering. In *Advances in neural information processing systems*, pages 3844–3852, 2016.